

Resenha: Model Context Protocol (MCP): Landscape, Security Threats, and Future Research Directions

O artigo apresenta uma análise técnica profunda sobre um novo padrão aberto que visa unificar a comunicação entre modelos de linguagem e ferramentas externas. O MCP surge para combater a fragmentação atual, onde cada integração entre inteligência artificial e fontes de dados exige implementações manuais e proprietárias. Ao propor um protocolo bidirecional, o estudo estabelece uma base para que agentes de IA possam descobrir e utilizar capacidades de forma dinâmica e segura.

A arquitetura do protocolo é estruturada em três componentes fundamentais: o cliente, o servidor e os recursos ou ferramentas. O cliente funciona como o ponto central de controle, gerindo as ligações a diversos servidores que expõem dados ou funções específicas. Esta separação permite que os modelos de IA interajam com sistemas de ficheiros, APIs e bases de dados através de um transporte agnóstico, que pode variar entre processos locais simples e comunicações remotas via HTTP.

Uma das contribuições mais detalhadas da pesquisa é a definição do ciclo de vida de um servidor MCP, dividido em quatro fases principais: criação, implementação, operação e manutenção. Estas fases englobam 16 atividades críticas, detalhando desde a definição inicial de esquemas de ferramentas até à monitorização de permissões em tempo real. Esta sistematização revela que a gestão de um servidor MCP exige um rigor constante para garantir que a ponte entre a IA e os dados sensíveis não se torne um ponto de falha.

O estudo dedica uma parte substancial à segurança, construindo uma taxonomia de ameaças que classifica os riscos de acordo com o tipo de atacante. São identificados quatro perfis de ameaça: desenvolvedores maliciosos, atacantes externos, utilizadores maliciosos e falhas de segurança inerentes ao sistema. Ao mapear 16 cenários distintos, os autores demonstram que a capacidade de execução de código e o acesso a recursos externos expandem significativamente a superfície de ataque dos sistemas baseados em IA.

Entre os riscos destacados, encontram-se os ataques de cadeia de suprimentos parasitários, onde componentes maliciosos são inseridos em bibliotecas de suporte ao MCP. Atacantes podem manipular servidores em repositórios públicos para induzir a instalação de ferramentas que, quando invocadas pelo modelo, realizam a exfiltração de dados confidenciais. Este tipo de vulnerabilidade sublinha a importância de verificar a integridade e a origem de todos os servidores integrados num ecossistema de agentes.

Outra vulnerabilidade crítica explorada é a injeção de comandos através de recursos externos, conhecida como injeção de prompt indireta. Se um servidor MCP lê dados de uma fonte não confiável, instruções maliciosas escondidas podem enganar o modelo de IA, levando-o a executar ações prejudiciais ou a ignorar

restrições de segurança. Esta ameaça é particularmente perigosa porque utiliza a confiança do modelo nas ferramentas autorizadas para subverter as intenções do utilizador original.

Para enfrentar estes desafios, o artigo propõe estratégias de mitigação baseadas em privilégios mínimos e isolamento. A execução de servidores em ambientes controlados, como sandboxes, é essencial para limitar o impacto de qualquer exploração bem-sucedida. Além disso, a implementação de controlos de acesso baseados em capacidades garante que o modelo só possa invocar ferramentas estritamente necessárias, reduzindo o risco de ações não autorizadas em larga escala.

Por fim, o projeto de investigação aponta para a necessidade de normalização e desenvolvimento de métodos de preservação da privacidade. O futuro do MCP depende da criação de sistemas de auditoria robustos e da verificação formal das interações entre modelos e ferramentas. Ao estabelecer estes padrões de segurança e interoperabilidade, o protocolo posiciona-se como a infraestrutura indispensável para que a próxima geração de inteligência artificial possa operar de forma autónoma e confiável em ambientes empresariais complexos.